

Análise de Séries Temporais - Trabalho 2

Davi Guerra Alves - Henrique Oliveira Dumay

2023-07-02

Apresentação

A série analisada consiste na série número 1686 pertencente ao banco de dados da competição de previsão M3, disponível no pacote *Mcomp* do software R. A série descreve o número de carregamentos com código *TD-AUTOUNITS*, mensalmente, de outubro de 1984 a setembro de 1993.




Figure 1: Comportamento da série ao longo do tempo

Decomposição MSTL




Figure 2: Decomposição MSTL

A decomposição MSTL mostra os componentes de tendência, sazonalidade e erro da série estudada. Percebe-se a presença de uma tendência crescente, com múltiplas sazonalidades que apresentam mudança do comportamento ao longo do tempo. É possível observar, graficamente, um alargamento da sazonalidade ao fim da série quando comparando ao início da série.

A presença do componente de tendência explicita a não-estacionariedade da série original. A função `ndiffs()` é utilizada para estimar o número de diferenças exigidas para tornar a série estacionária por meio de um teste de raiz unitária, com a hipótese nula de que a série tem raízes estacionárias contra a hipótese alternativa de que a série tem raiz unitária. O teste retorna o menor número de diferenças exigidas para o teste em um nível de significância de 95%. Já a função `nsdiffs()` utiliza testes de raiz unitária para determinar o número de diferenças sazonais para tornar a série estacionária.

Com o uso das funções acima, obteve-se o valor para $d = 1$ e $D = 0$. Os modelos candidatos terão a forma:

$$SARIMA(p, 1, q) \times (P, 0, Q)_{12}$$

A estacionariedade da série pode ser testada utilizando o teste Kwiatkowski-Phillips-Schmidt-Shin (KPSS), com a hipótese nula de que a série é estacionária. O teste resulta em um valor de 0.0221285, com p-valor de 0.1, que não nos permite rejeitar a hipótese nula a um nível de significância $\alpha = 0,05$.

Consideramos que a série é, agora, estacionária, observamos os gráficos da função de autocorrelação (ACF) e da função de autocorrelação parcial (PACF) em busca de possíveis autocorrelações entre os diferentes atrasos

da série. Os gráficos a seguir ilustram a série diferenciada, assim como os gráficos das funções de ACF e PACF.

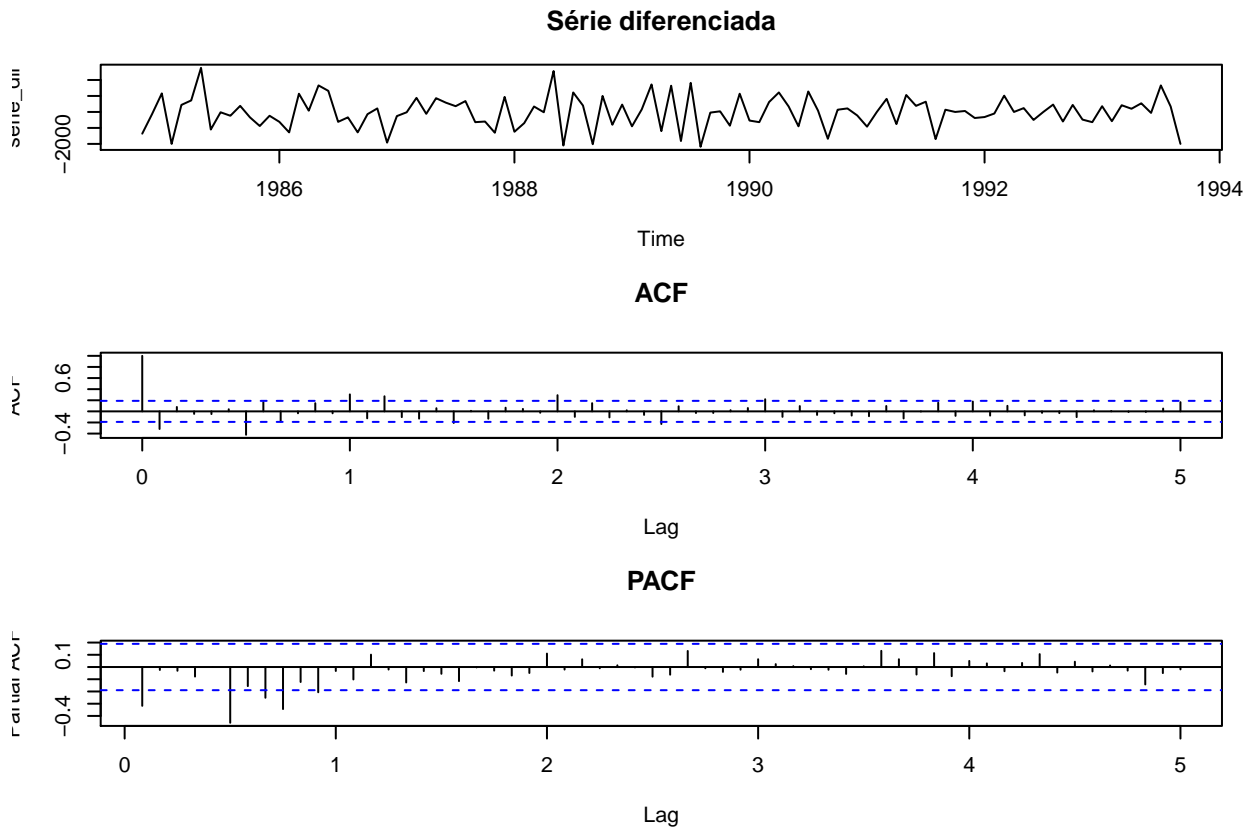


Figure 3: Gráficos ACF e PACF

Dos gráficos apresentados, pode-se afirmar que a série diferenciada não apresenta um padrão claro de autocorrelações simples e sazonais que permita inferir diretamente a modelagem. Neste sentido, serão testados valores diferentes para p , P , q e Q e os diferentes modelos serão comparados por meio do critério AIC.

Para os diferentes valores de (p, q, P, Q) teremos:

```
## p = 0 , q = 0 , P = 0 , Q = 0 , AICc = 1606.318
## p = 0 , q = 1 , P = 0 , Q = 0 , AICc = 1568.851
## p = 0 , q = 2 , P = 0 , Q = 0 , AICc = 1566.733
## p = 2 , q = 3 , P = 0 , Q = 0 , AICc = 1559.206
## p = 0 , q = 1 , P = 0 , Q = 1 , AICc = 1543.946
## p = 0 , q = 2 , P = 0 , Q = 1 , AICc = 1541.794
## p = 1 , q = 1 , P = 0 , Q = 1 , AICc = 1541.464
## p = 2 , q = 3 , P = 0 , Q = 1 , AICc = 1540.11
```

O modelo com menor AICc foi o $SARIMA(2, 1, 3) \times (0, 0, 1)_{12}$.

Os coeficientes do modelo proposto, portanto, serão:

```
fit_arima <- Arima(M3[[id]]$x, order=c(2,1,3), seasonal=c(0,0,1))
fit_arima
```

```
## Series: M3[[id]]$x
```

```
## ARIMA(2,1,3)(0,0,1)[12]
##
## Coefficients:
##          ar1      ar2      ma1      ma2      ma3      sma1
##      -0.5572 -0.7207  0.0136  0.2117 -0.8811  0.4280
## s.e.   0.1001   0.1019  0.0959  0.1002   0.0907  0.0877
##
## sigma^2 estimated as 662685:  log likelihood=-869.61
## AIC=1753.21   AICc=1754.34   BIC=1771.92
```

O modelo proposto, portanto, tem os seguintes coeficientes:

$$\phi_1 = -0,5572; \phi_2 = -0,7207; \theta_1 = 0,0136; \theta_2 = 0,2117; \theta_3 = -0,8811; \vartheta = 0,4280$$